A New Data Science Model With Supervised Learning and Its Application on Pesticide Poisoning Diagnosis in Rural Workers

JAQUELINE C. S. CARVALHO, TALES C. PIMENTA (Senior Member, IEEE), ALESSANDRA C. P. SILVERIO, MARCOS A. CARVALHO AND JOAO PAULO C. S. CARVALHO

PUBLICADO EM 11 DE MARÇO DE 2024 PELA IEEE

MARCOS P. OLIVEIRA & GUILHERME ULHOA

Problema

Diagnosticar intoxicação por agrotóxicos

Problema Prático

Diagnosticas intoxicação por agrotóxicos

Falta de testes biológicos padronizados

Escassez de profissionais de saúde capacitados

Problema Técnico

Preparação dos dados pré processamento

- Base de dados ruidosa
- Auxência de orientação prática e detalhada

Problema Técnico

Preparação dos dados pré processamento

- Base de dados ruidosa
- Auxência de orientação prática e detalhada

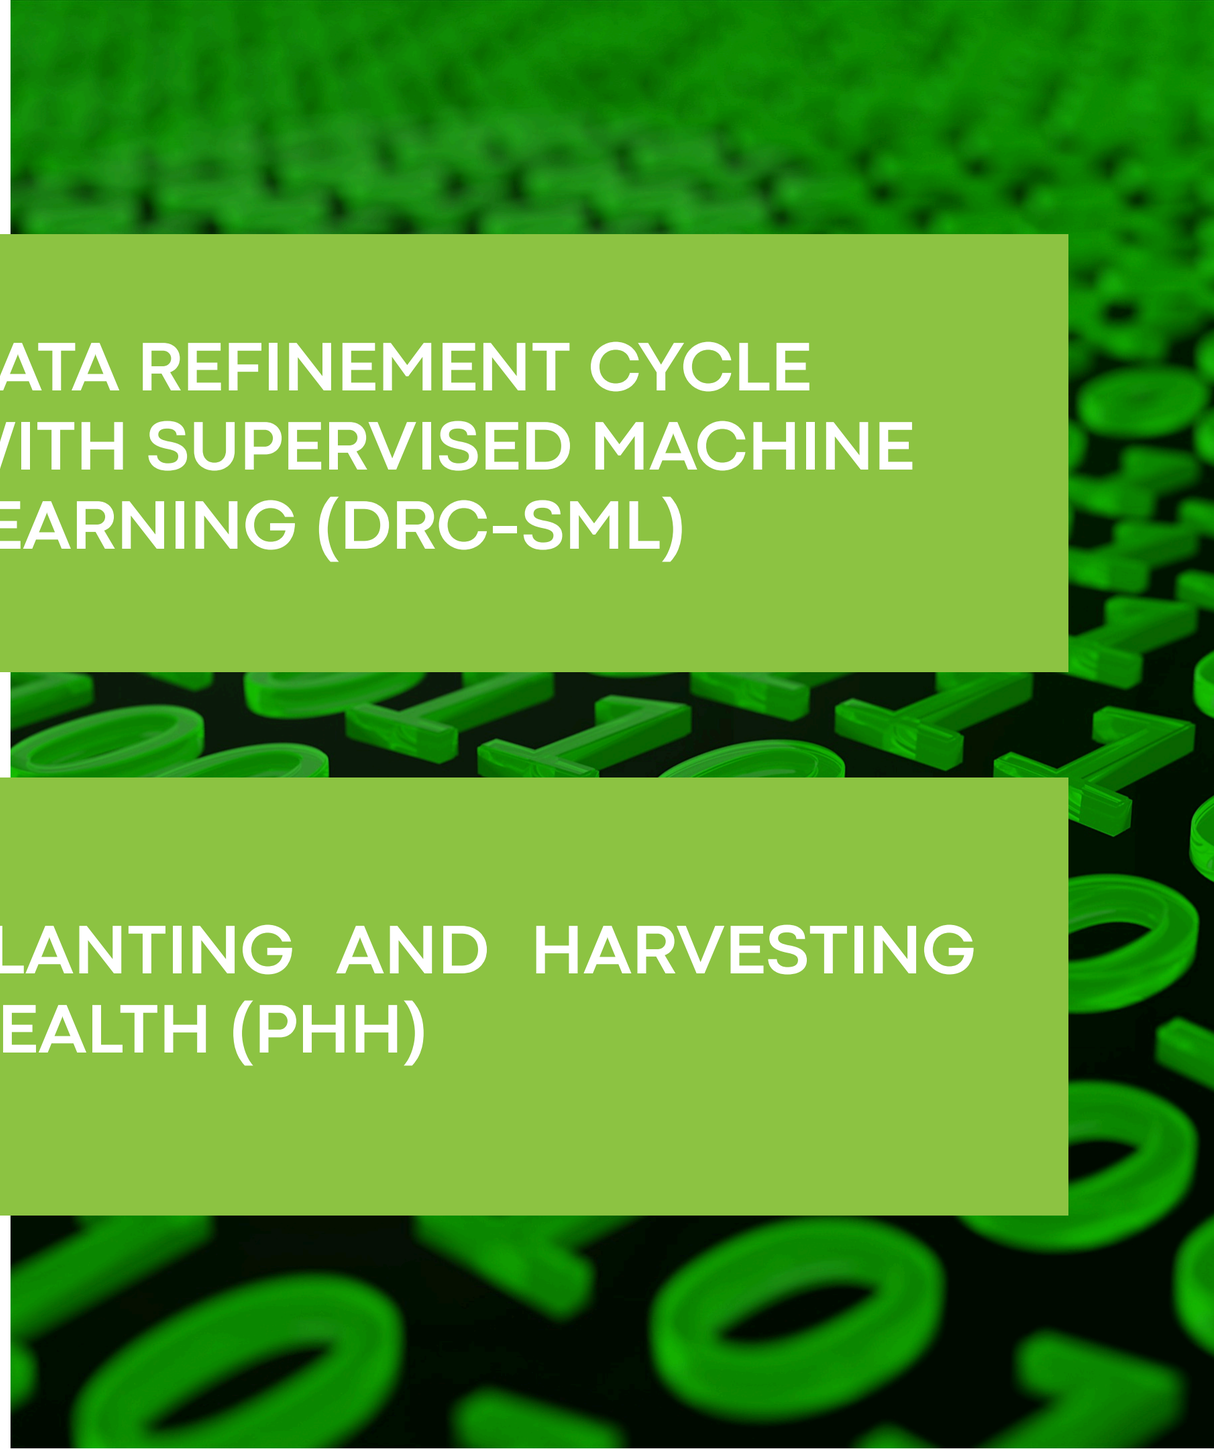

DATA REFINEMENT CYCLE WITH SUPERVISED MACHINE LEARNING (DRC-SML)

PLANTING AND HARVESTING HEALTH (PHH)

DRC-SML

Metodologia para projetos de ciência de dados desde a coleta ao refinamento.

- Sistemático
- Documentado
- Transparente
- Rastreável

PHH

Ferramenta de auxílio no diagnóstico de intoxicação por agrotóxicos em trabalhadores.

Base de Dados

- Pesquisa biomédica sul de Minas Gerais
- 1027 amostras (trabalhadores rurais)
- 121 atributos por amostra:
  - Socioeconômicos
  - Histórico clínico
  - Exposição ocupacional
  - Dados laboratoriais
- Problemas:
  - Valores ausentes
  - Dados multivalorados
  - Atributos irrelevantes
  - Desbalanceamento

CARVALHO, ET. AL

Base de Dados

- Pesquisa biomédica sul de Minas Gerais
- 1027 amostras (trabalhadores rurais)
- 121 atributos por amostra:
  - Socioeconômicos
  - Histórico clínico
  - Exposição ocupacional
  - Dados laboratoriais
- Problemas:
  - Valores ausentes
  - Dados multivalorados
  - Atributos irrelevantes
  - Desbalanceamento

41 ATRIBUTOS REMOVIDOS

79 ATRIBUTOS DE CONDIÇÃO

1 ATRIBUTO DE DECISÃO

REDUCTS À 5 ATRIBUTOS

CARVALHO, ET. AL

DRC-SML

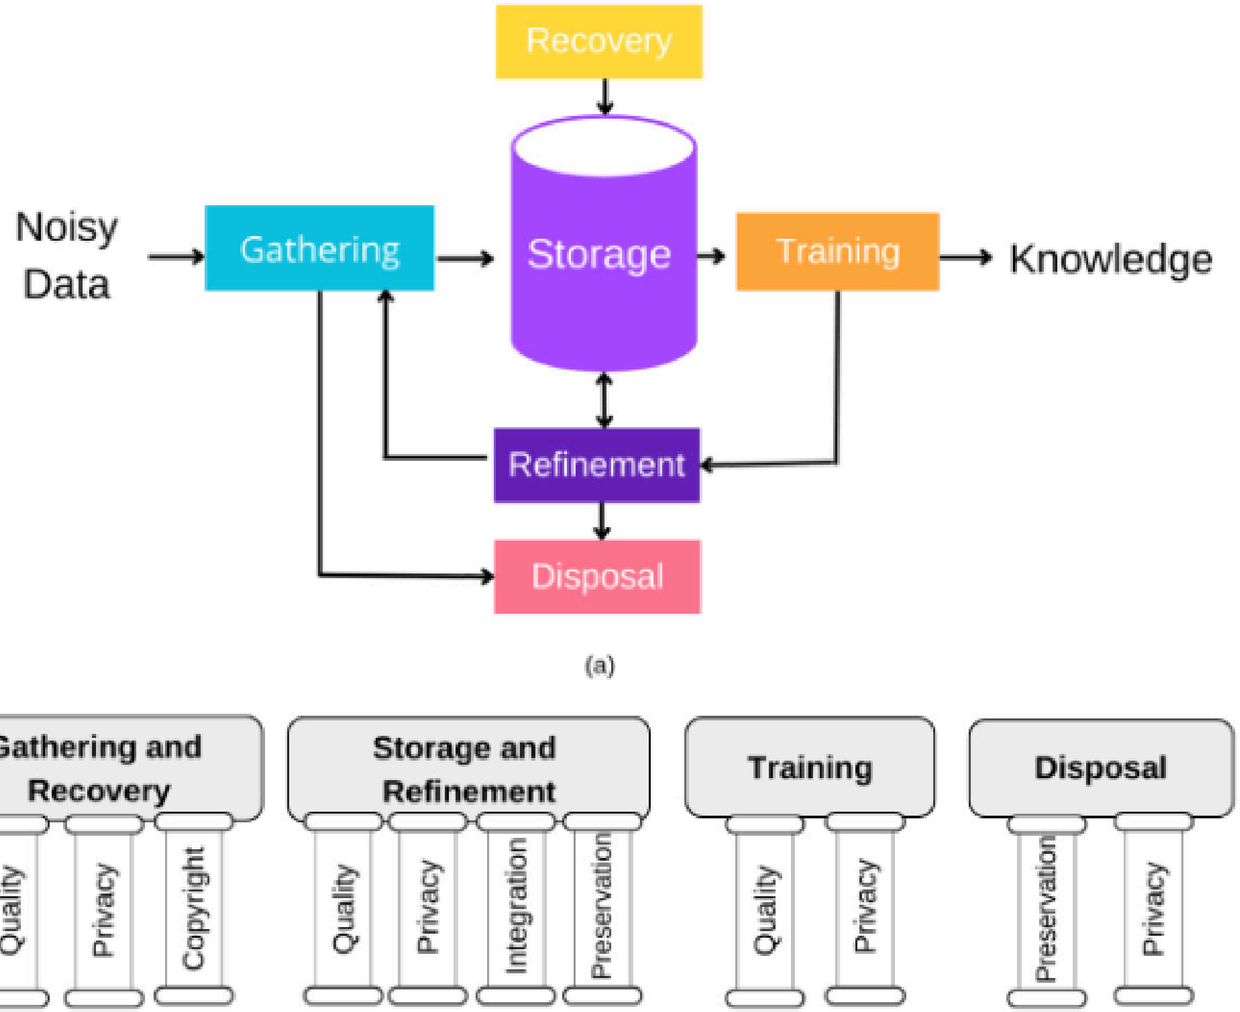

CARVALHO, ET. AL

Coleta

Manualmente, por pesquisa
Digitalmente, utilizando dados que já existem

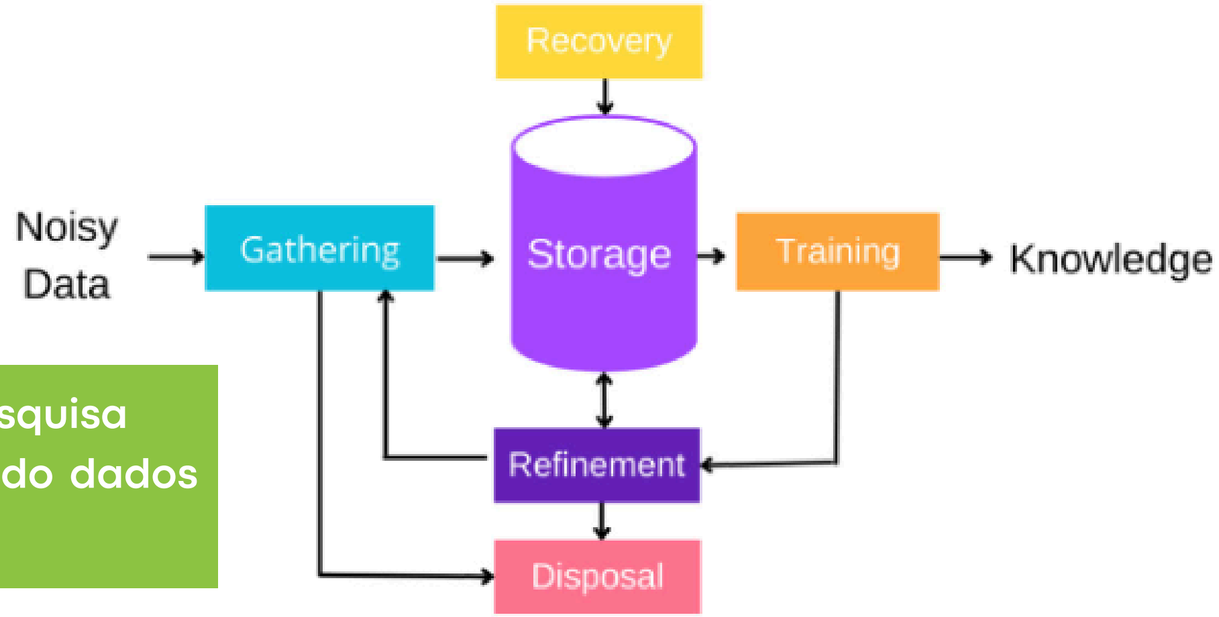

(a)

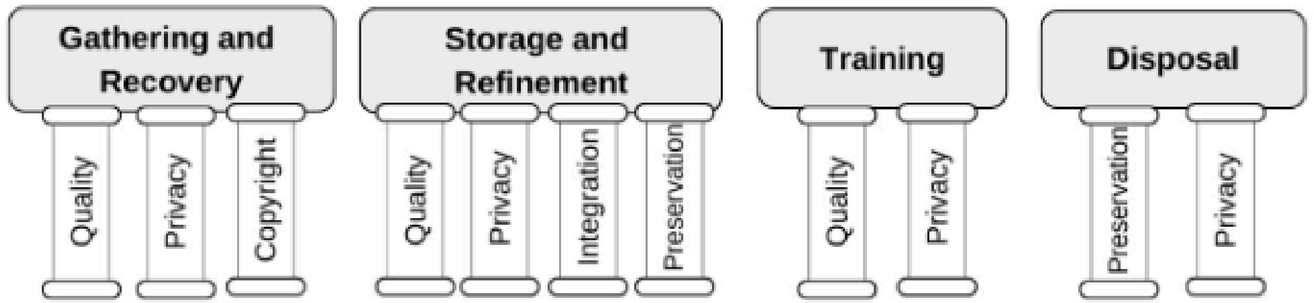

CARVALHO, ET. AL

Descarte

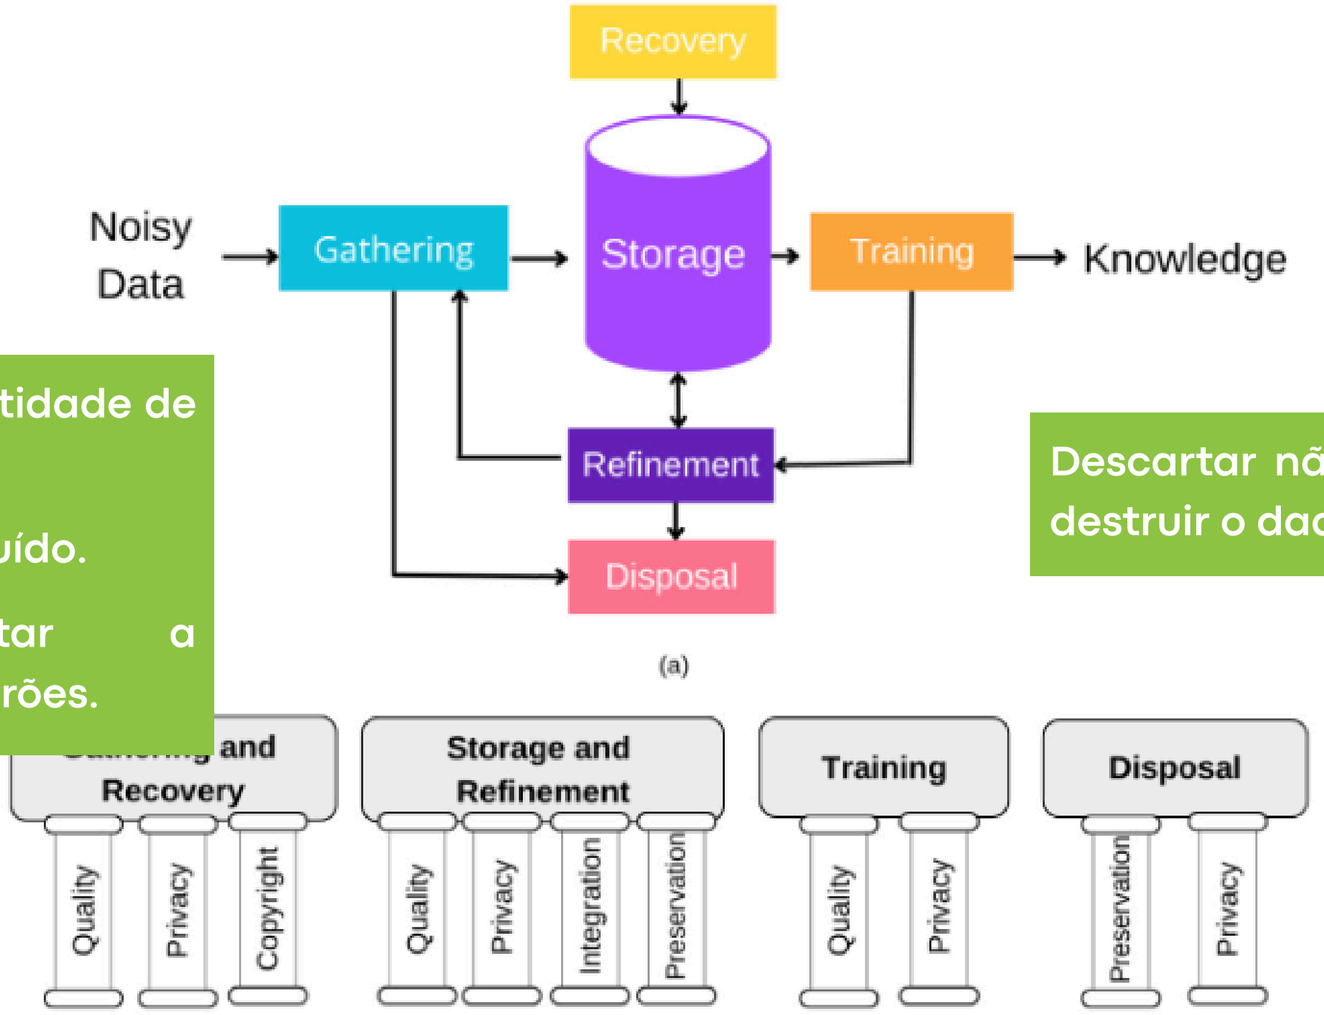

Aumentam a quantidade de dados a processar.

Podem introduzir ruído.

Podem dificultar a descoberta de padrões.

Descartar não significa destruir o dado.

CARVALHO, ET. AL

Documentação

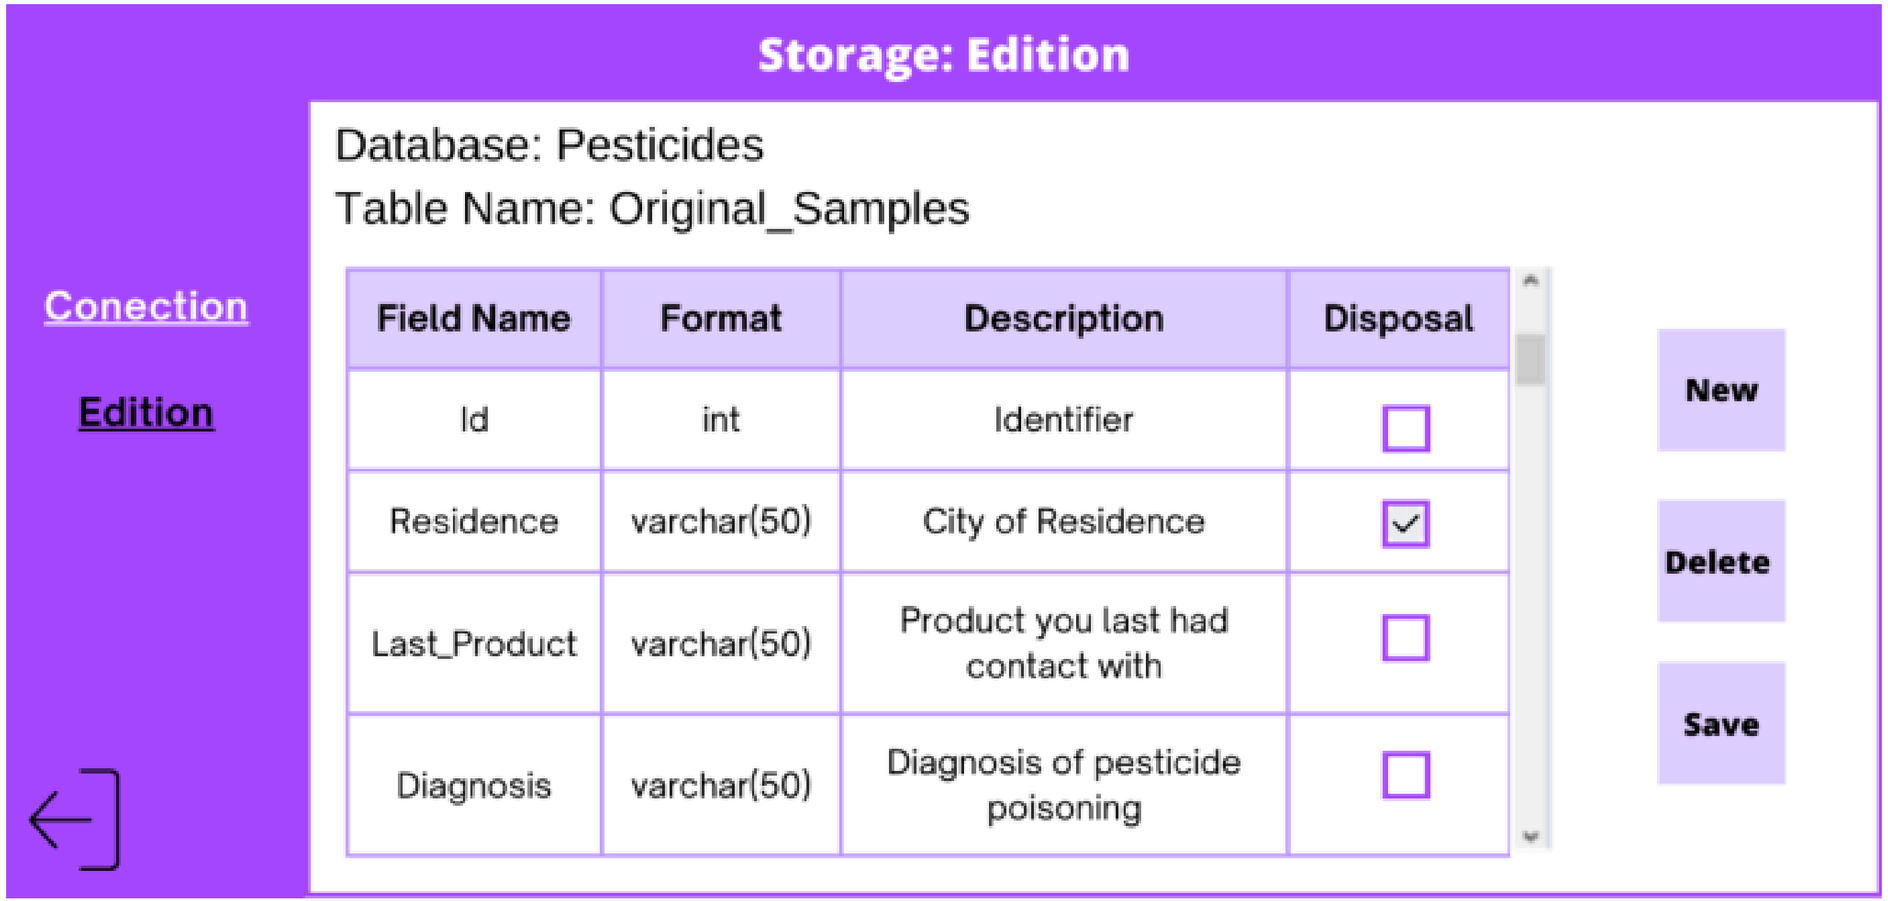

Armazenamento

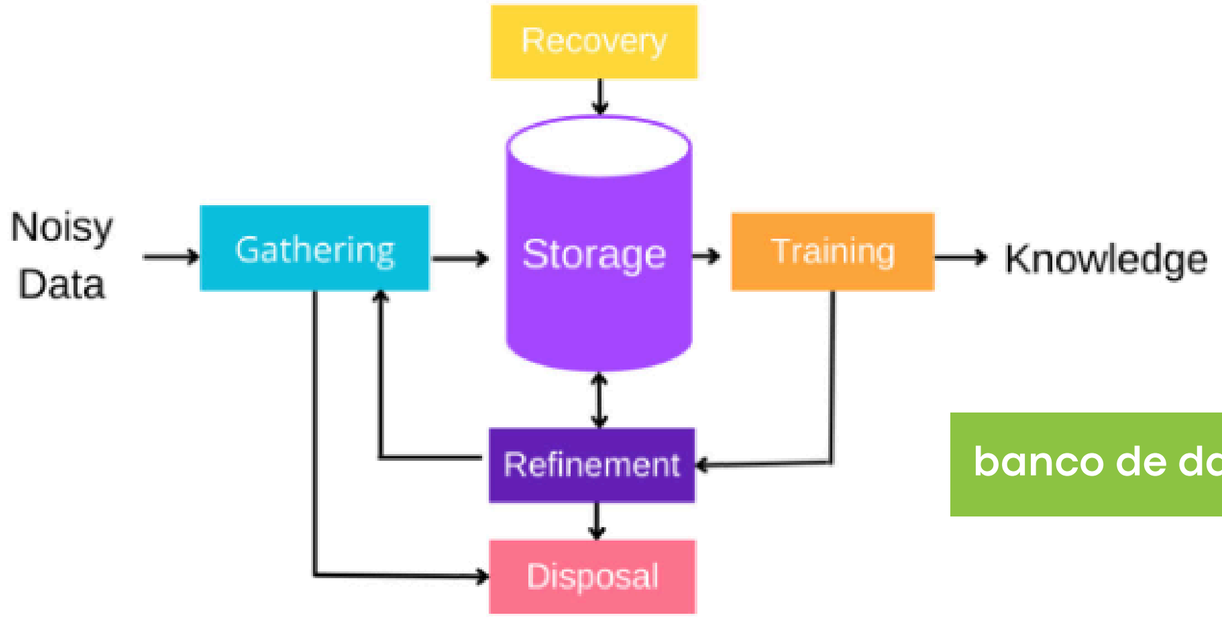

(a)

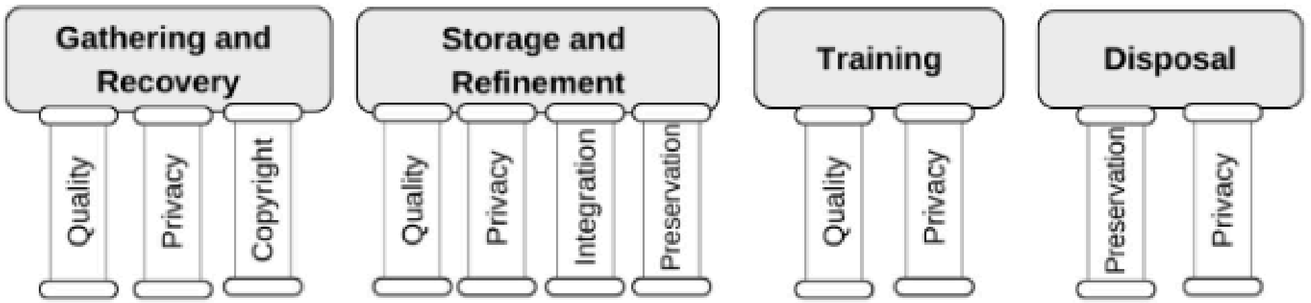

banco de dados relacional

CARVALHO, ET. AL

Refinamento

Tratamento de valores ausentes.
Padronização.
Exclusão de atributos irrelevantes.
Transformação dos dados.
Discretização de dados contínuos.
Tratamento de atributos multivalorados.

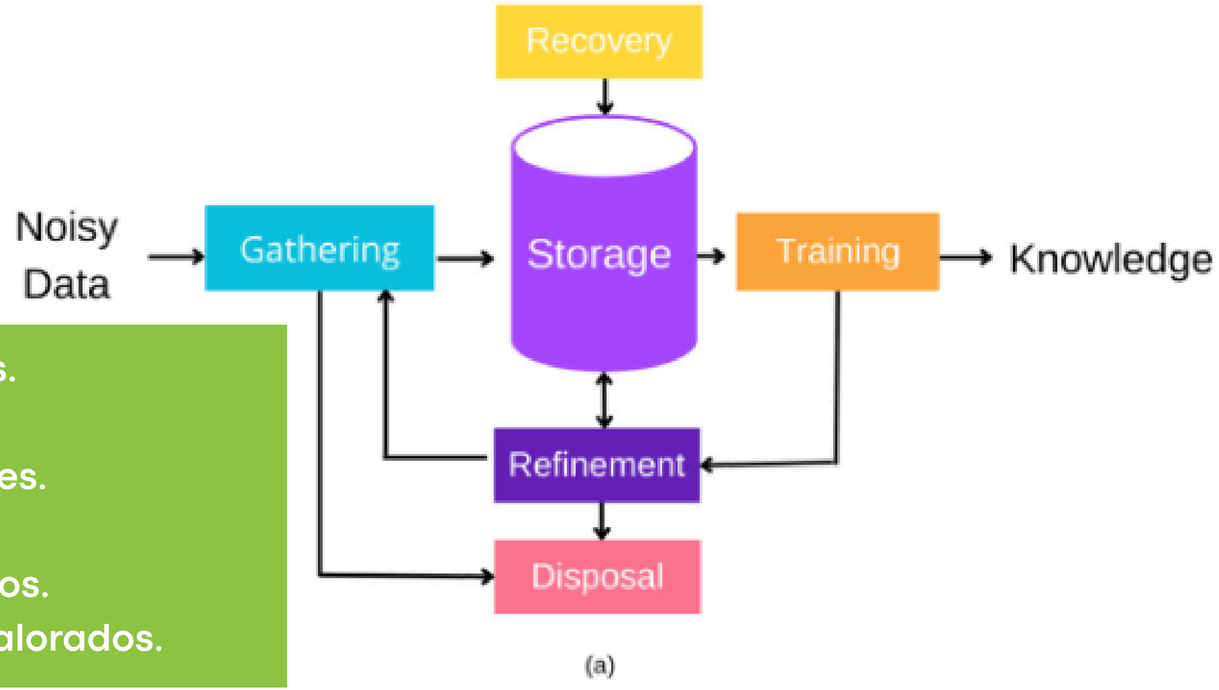

(a)

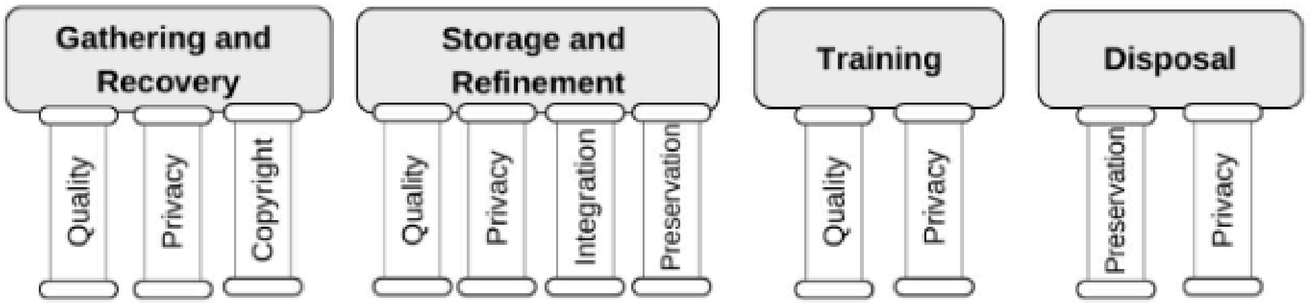

CARVALHO, ET. AL

Documentação

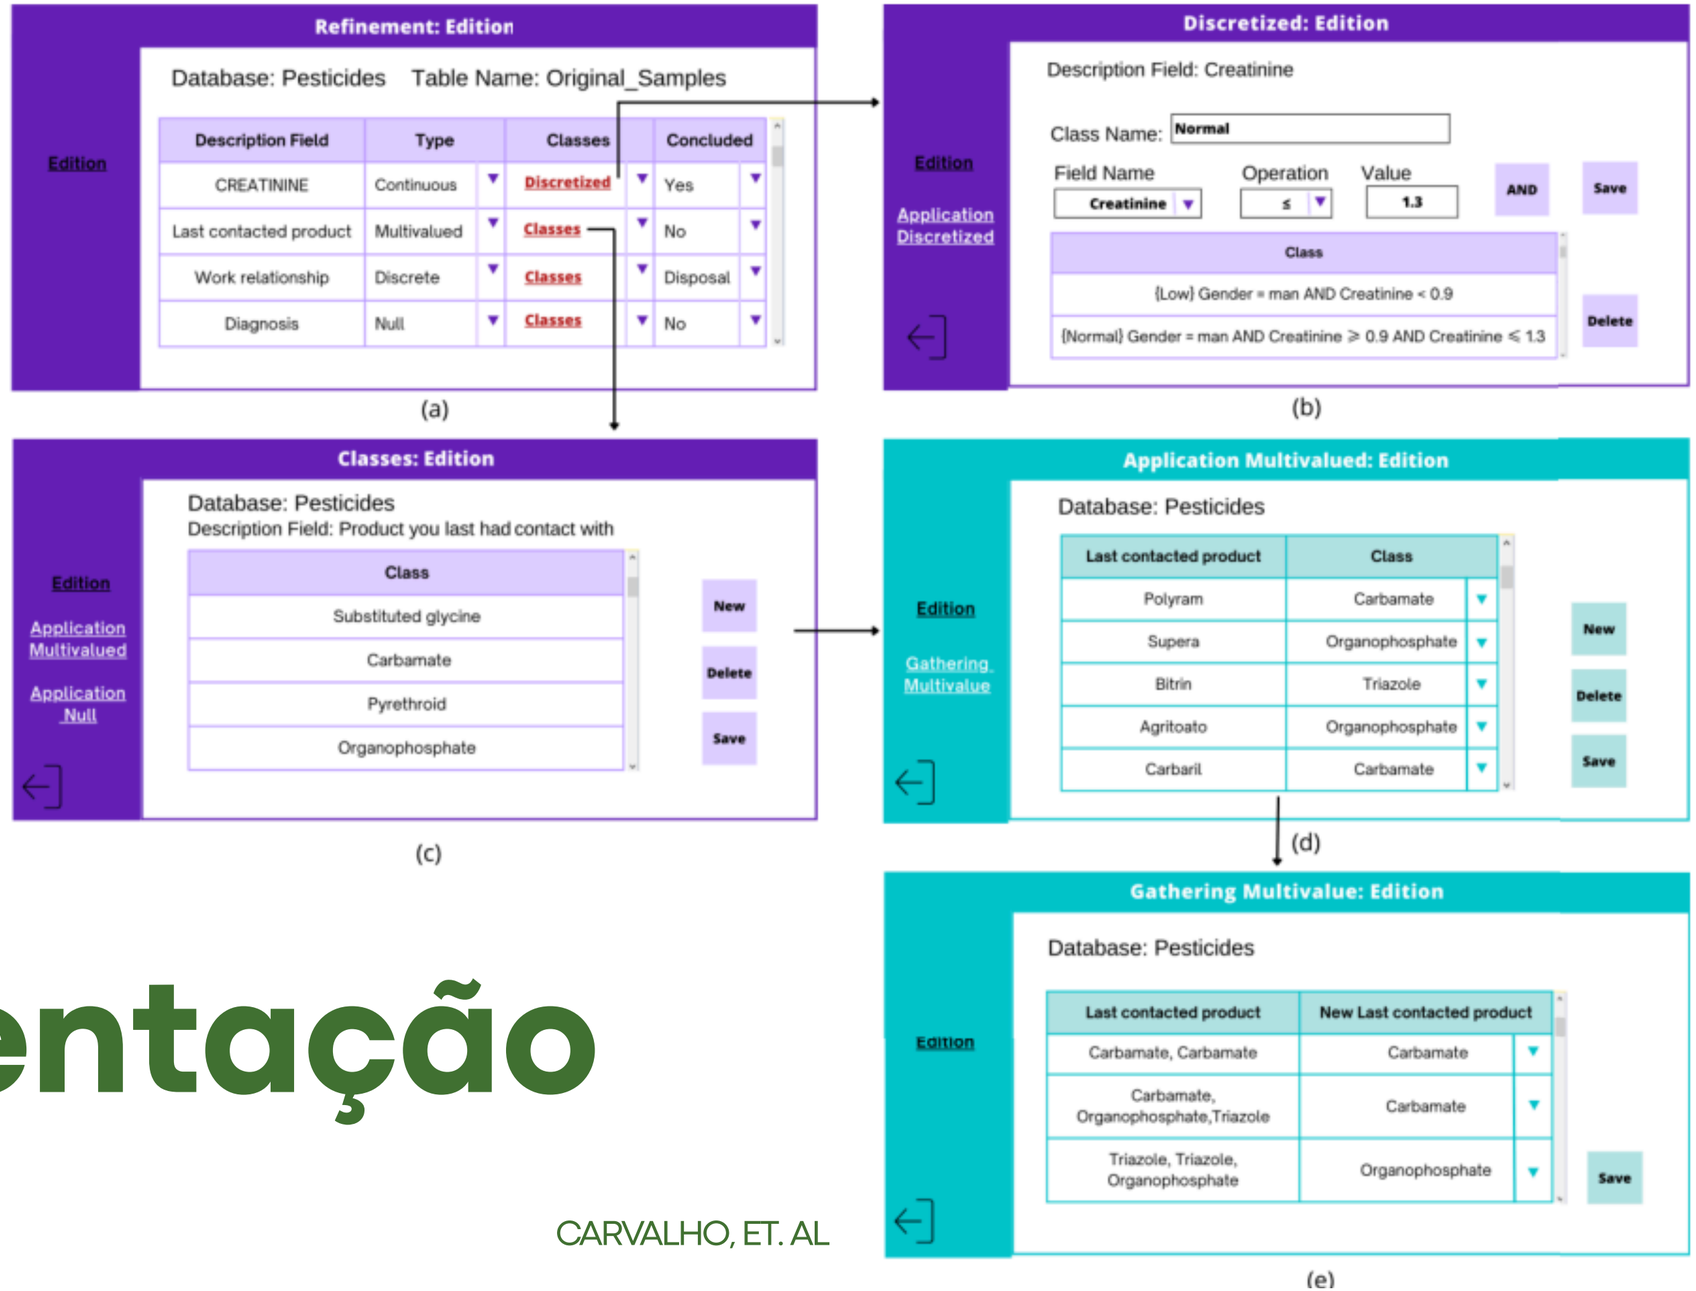

CARVALHO, ET. AL

Treinamento

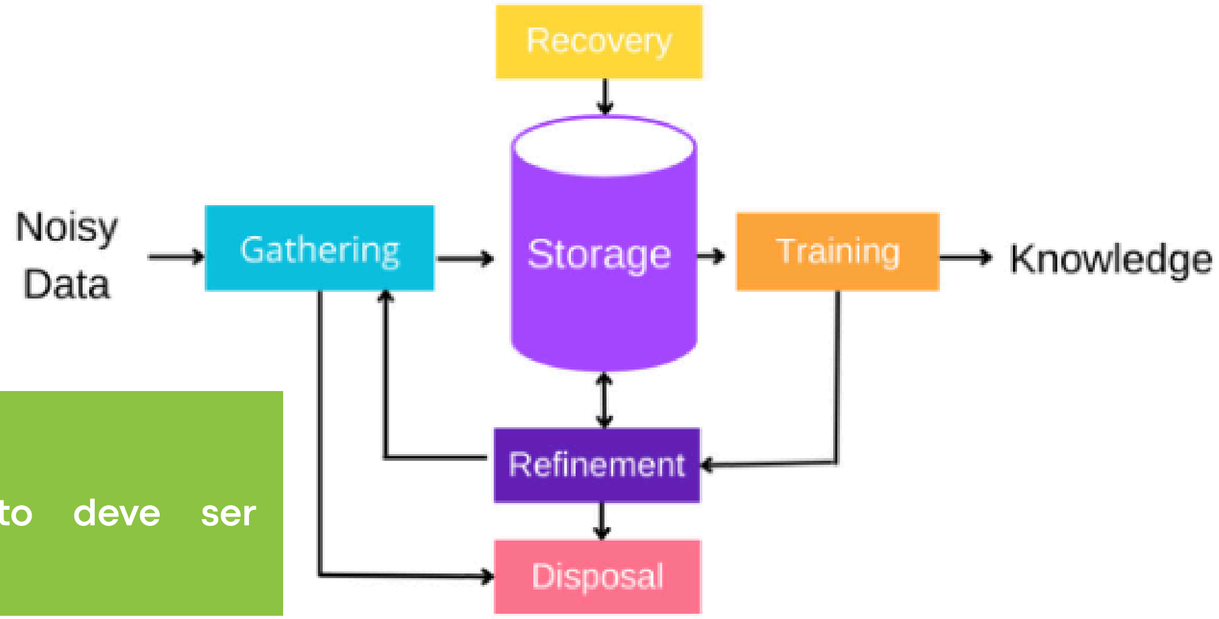

(a)

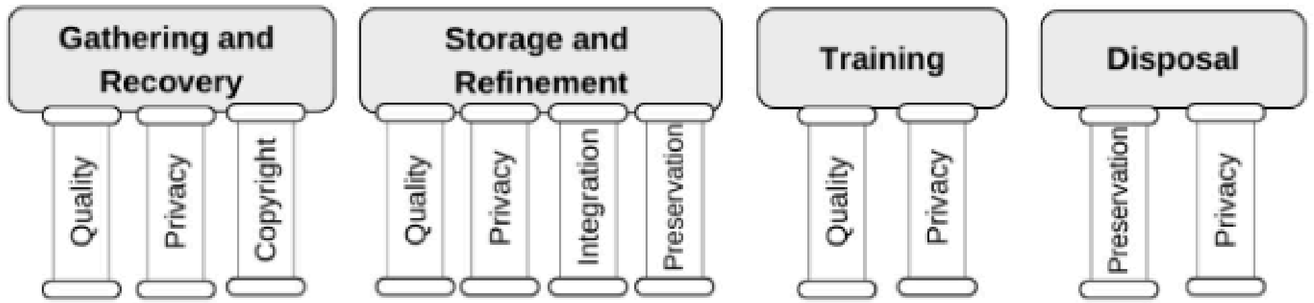

Rough Set Theory (RST)

Cada sessão de treinamento deve ser documentada.

CARVALHO, ET. AL

Ciclo + recuperação

Reavaliação e não troca de modelo

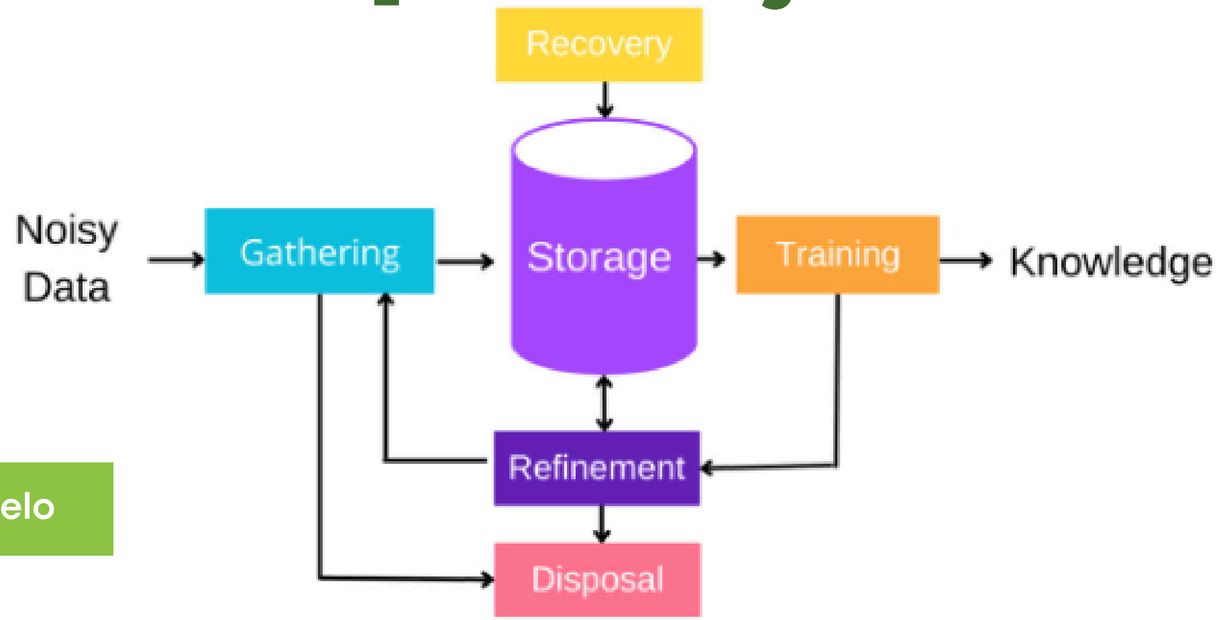

(a)

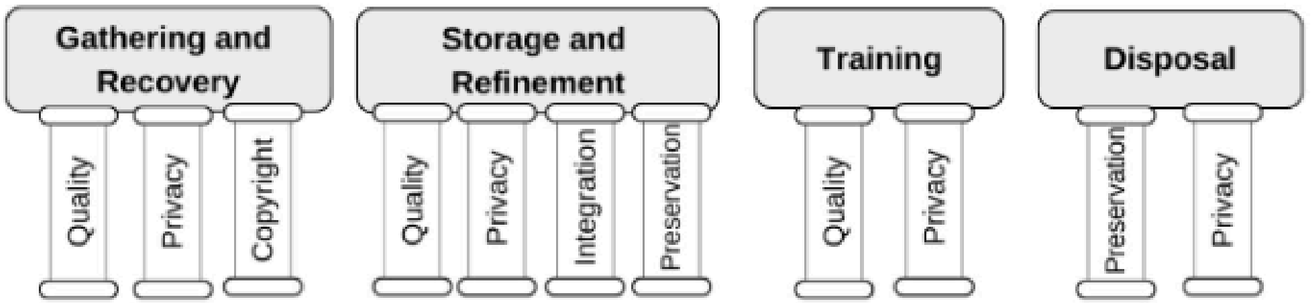

CARVALHO, ET. AL

Experimento

Separação dos atributos

79 atributos condicionais divididos em 12 grupos (1 completo)

k-fold cross validation (k = 4)

1027 amostras → **9** categorias → **4** partições

Teste	Treinamento	Validação
A	B + C + D	A
B	A + C + D	B
C	A + B + D	C
D	A + B + C	D

Resultados

Refinamento dos dados

121 atributos iniciais

41 excluídos

80 atributos utilizados

Treinamento

48 sessões de treinamento

12 agrupamentos válidos

Reducts mínimos com 5 atributos

Classificação

Em um dos reducts, com 27 regras de decisão, obteve-se 99,61% de acurácia

SE *CH_T*, *CH_E* e *CH_P* = baixo
E *AST* e *creatinina* = normal
ENTÃO diagnóstico = IA–HP–CHPD

Pontos fortes

Metodologia estruturada

O processo pode voltar para etapas anteriores quando o treinamento mostra que novos refinamentos são necessários

Redução de atributos

Redução significativa da quantidade de informações utilizadas nas classificações

Interpretabilidade

É possível determinar quais condições estão associadas a determinados diagnósticos

Limitações

Ausência de comparação

Ausência de uma comparação experimental com outros modelos de Machine Learning utilizando o mesmo conjunto de dados.

Dados ruidosos

Utilização oversampling e undersampling para tentar equilibrar as categorias durante a validação.

Validação limitada

Apesar da alta acurácia geral, em alguns testes uma das categorias apresentou recall de 0%

Trabalhos Futuros

Armazenamento	Machine Learning	Coleta de dados
Banco de dados orientado a objetos e grafos	Incorporar diferentes métodos de ML	Desenvolvimento de uma API para coleta de dados

Referência

J. C. S. Carvalho, T. C. Pimenta, A. C. P. Silverio, M. A. Carvalho and J. P. C. S. Carvalho, "A New Data Science Model With Supervised Learning and its Application on Pesticide Poisoning Diagnosis in Rural Workers," in IEEE Access, vol. 12, pp. 40871-40882, 2024, doi: 10.1109/ACCESS.2024.3375764.
keywords: {Data models;Data science;Support vector machines;Machine learning algorithms;Training;Solid modeling;Pesticides;Decision support systems;Machine learning;Toxicology;Diagnostic expert systems;Data science;decision support system;machine learning;pesticide poisoning diagnosis},